

專題成果報告書

智慧教學

— 應用自然語言處理技術標記教材重點及自動出題與評分

一、摘要

現今疫情嚴重，遠距教學需求日益提高。我們利用自然語言處理(Natural Language Processing)及遷移式學習(Transfer Learning)等技術，對當做輸入的教材內容，使用 Python Keyphrase Extraction (PKE) 等相關的監督式和非監督式模型萃取重點關鍵字，幫助學生標記學習重點。並針對關鍵句透過 Transfer Text-to-Text Transformer (T5) 進行問題生成幫助教師出題。最後，對於標準答案及學生答案，自動做句子相似度的評分，做為考試評分的參考；另嘗試 Fine-tune 以 BERT 為基礎架構的預訓練模型，評估問題生成的出題的難度。希望能讓學生更快找到重點，並能讓教師更有效率地提升教學品質，減輕學生和教師負擔，期盼創造雙贏局面！

二、研究動機與研究問題


(一)、研究動機

1. **疫情嚴重遠距教學：**近兩年全球疫情嚴重，許多國家都有無法到校面對面授課的問題，線上課程及遠距教學需求日益提高。
2. **時間有限提高效率：**台灣學生課程學分普遍較多，且大學有許多不同事務需要兼顧，希望能有好的方法幫助學生提高吸收效率及學習成果。
3. **提升學習品質：**教授除了授課教學外，亦有許多重要計畫及研究在身，期待能有簡單的方法幫助教授出題，減輕教授出題負擔，節省下的時間便能用來提升教學及研究品質，也能讓學生有更多答題練習機會。

因此，我們期待利用 NLP 自然語言處理技術，輔助教學和學習過程，提升學生學習和教師教學品質！

(二)、研究問題

本專題研究將目標鎖定在利用 NLP 自然語言處理技術，對教材內容萃取重點關鍵字，幫助學生標記學習重點，並針對關鍵字句進行問題生成幫助教師出題。最後，對於標準答案及學生答案，自動做句子相似度的評分，做為考試評分的參考。另嘗試運用遷移式學習(Transfer Learning)技術，使用以 BERT 為基礎架構的預訓練模型對下游任務做 Fine-tune，評估問題生成的出題難度。



圖一、本專題研究概念圖

三、研究方法及步驟


(一)、「針對教材重點出題」任務：

針對此任務，我們為了提升問題生成的表現，將此議題先分成兩個子任務，分別為**萃取關鍵字**(Keyword Extraction)和**問題生成**(Question generation)。

1. 萃取關鍵字(標記教材重點)

(1) 概念

在此簡單說明萃取關鍵字的大致流程，首先對教材文本做資料預處理，去除文本雜訊，取出教材的文字部分，再進行資料分析。接下來是文本數據和頻率的向量化。最後依據監督式或非監督式的不同方法，分析文本頻率來排序關鍵字結果，取出最重要的文本關鍵字。



圖二、關鍵字萃取概念流程圖

(2) 展示文本說明

在往後的實例展示中，我們使用論文 Language Models are Unsupervised Multitask Learners 的 Abstract 作為測試的展示用文章。節錄原文如下圖：


Natural language processing tasks, such as question answering, machine translation, reading comprehension, and summarization, are typically approached with supervised learning on task-specific datasets. We demonstrate that language models begin to learn these tasks without any explicit supervision when trained on a new dataset of millions of webpages called WebText. When conditioned on a document plus questions, the answers generated by the language model reach 55 F1 on the CoQA dataset matching or exceeding the performance of 3 out of 4 baseline systems without using the 127,000+ training examples. The capacity of the language model is essential to the success of zero shot task transfer and increasing it improves performance in a log linear fashion across tasks. Our largest model, GPT2, is a 1.5B parameter Transformer that achieves state of the art results on 7 out of 8 tested language modeling datasets in a zero-shot setting but still underfits WebText. Samples from the model reflect these improvements and contain coherent paragraphs of text. These findings suggest a promising path towards building language processing systems which learn to perform tasks from their naturally occurring demonstrations.

圖三、測試的展示用文章

(3) 方法比較

我們使用數種不同套件模型，並比較他們在關鍵字萃取的表現，以下四種是測試中相對表現好的。

- a. PKE (Python-Base Keyphrase Extraction)：提供監督式和非監督式兩種類型的方法，而且有大量預訓練模型可使用，不僅能對關鍵字重要度評分，還能指定關鍵字數量。以下解說 PKE 的概念流程。首先，由 reader 讀取文本，再從中選擇關鍵字候選詞（即符合關鍵字條件的單詞和短語）。緊接著若是非監督式方法，會使用候選權重函數對候選關鍵詞排序，而若是監督式方法則會根據 model 提取的特徵，做關鍵字重點程度的分類。最後一步會將 N 個權重最高的候選關鍵詞，作為輸出的關鍵字短語。另外，本專題中 PKE 監督式方法的模型，所使用的訓練資料集為 SemEval-2010 dataset 關係數據集。



圖四、PKE 流程圖

- b. TextRank：是非監督式方法。將詞句間的關聯以網路圖呈現，每一詞句為一個節點，而詞句間會相連，連接的權重為句子之間的相似程度。原理是計算不同詞句節點權重所占的比例。優點是不需數據集訓練，且繼承了 PageRank 的思想，效果相對較好。而相對於 TF-IDF 方法，TextRank 可以更充分的利用文本元素之間的關

係。缺點是雖然考慮到了詞句之間的關係，但是仍傾向於將頻繁詞作為關鍵詞，且因需要構建詞圖，所以速度較慢。

- c. **KeyBERT**：是監督式的方法。運作流程是，使用預訓練的 BERT Embedding Models，對輸入文本做 embedding，將文本以固定大小的向量表示，此向量也表示著文本的語義。接著，從同一文本中提取關鍵字和表達式（n-gram），然後將每個關鍵字 embedded 到一個固定大小的向量中，該向量與用於 embedded 文檔的模型相同。最後，計算關鍵字 embedding 和文本 embedding 之間的餘弦相似度，提取出最高餘弦相似度的關鍵字。比起一般經典關鍵字提取技術，使用 BERT 語言模型可使其有語義的效果，達到查找文章中與文章本身最相似的短語的目的。其優點是 BERT Embedding Models 的預訓練模型可以直接套用，亦可再對下游任務做進一步的 Fine-tune。而 API 使用上可以設定的關鍵字長度，而不僅限於抓取單一單字的關鍵字。
- d. **BERT Keyword Extractor**：是監督式的方法。需要先對 BERT 的預訓練模型做萃取關鍵字的訓練，訓練資料集使用的是 SemEval 2010 dataset 關係數據集。在萃取關鍵字上，此模型設計輸出的關鍵字為 0~2 個字不等，關於其輸入，主要設計是針對句子輸入而非整段文章，當輸入整段文章，效果可能較不理想。因此，對於文本輸入，我們會先將文章「以句號為標準」拆為數個句子，再用 for 迴圈將儲存句子的 list 丟到 BERT-Keyword-Extractor 裡抓關鍵字。

(4) 關鍵字萃取方法比較與輸出關鍵字結果

以下簡單呈現各方法萃取出的關鍵字結果，我們認為 PKE 的表現較符合我們的期待，PKE 的詳細表現將於下節「專題研究成果及探討」討論。

套件模型	PKE (Python-Base Keyphrase Extraction)	TextRank	KeyBERT	BERT Keyword Extractor
ML類別	監督式和非監督式方法	非監督式方法	監督式方法	監督式方法
方法原理	利用監督式和非監督式模型，做關鍵字重點程度的分類排序，挑出權重最高的N個字，即為關鍵字	詞句關聯以圖呈現，一詞句一節點，連接權重為句子相似度。原理是計算不同節點權重所占的比例。	背後為DistilBERT，用BERT-embeddings和餘弦相似性(cosine similarity)萃取關鍵字	對BERT預訓練模型做萃取關鍵字的訓練，進而得到能萃取關鍵字的模型
✓ 優點 x 缺點	✓ 大量預訓練模型可以套用測試 ✓ 重要度評分 ✓ 指定關鍵字數量	✓ 不需數據集訓練 ✓ 繼承PageRank思想，表現不錯 x 傾向將頻繁詞作為關鍵詞	✓ 預訓練模型可直接套用 ✓ 設置關鍵詞長度(不僅限一個單字) ✓ 重要度評分	x 訓練模型較費時 x 關鍵字僅有0~2個字不等 x 對句子分析，文章不適合
關鍵字萃取結果	language models、tasks、webtext、task specific datasets	models、model、modeling、language	learning、algorithm、training、class、mapping.....	language、processing、model

表一、關鍵字萃取套件模型比較


2. 問題生成

(1) 概念

我們使用的模型架構為 T5 base，也就是透過 Text-to-Text Transfer Transformer (T5)模型來生成問題。我們運用 question_generator 套件，以利用來自 HuggingFace Transformers 的預訓練模型進行問題生成。

(2) Text-to-Text Transfer Transformer (T5)概念簡介

所謂的 Text-to-Text 就是使用一個統一框架，將所有 NLP 任務都轉換成文本到文本的任務，藉此可使用同樣的模型、損失函數、訓練過程、解碼過程，來完成所有的 NLP 任務。T5 的重要貢獻就是給整個 NLP 預訓練模型領域提供一個通用框架。下圖可呈現 T5 的 Text-to-Text 特色。



圖五、T5 Text-to-Text 的框架概念圖

(3) 實驗方法

利用 T5 模型架構來進行問題生成，而使用的模型來自於 HuggingFace 的 Transformers 預訓練模型庫中的「iarfmoose/t5-base-question-generator」(該模型已在幾個著名的 QA 數據集，包括 SQuAD v2.0、RACE、CoQA 和 MSMARCO 組成的數據集做 Fine-tune)。我們運用上述模型，自行根據我們「教材問題生成」的任務需求，使用「Kaggle 資料集 — Python Questions from Stack Overflow」來對模型進行下游任務的微調 (Fine-tune)。

(4) T5 生成問題結果示例

這是我們利用 T5 做問題生成的結果示例，針對輸入的文本，T5 可以生成的一系列混合類型的問題和答案。答案是從輸入文本中提取的完整句子或短語，題目部分可自訂題數及題目類型(包括選擇題或問答題)。下面兩張圖片是使用 T5 對測試文章做問題生成的結果。其中，圖六是問答題，圖七是選擇題。

Q: What are the most common tasks that are taught by a natural language model?
A: Natural language processing tasks, such as question answering, machine translation, reading comprehension, and summarization, are typically approached with supervised learning on task specific datasets.

圖六、T5 base 模型生成「問答題」示例圖

Q: How many F1 answers are generated by the CoQA dataset?
A: 1. 8 2. 1 3. 55 (correct) 4. 5B

圖七、T5 base 模型生成「選擇題」示例圖

(二)、「自動評分」任務：

1. 學生回答評分

(1) 概念

對於學生的回答句，將學生回答和前述 T5 生成問題時的答案句，使用句子相似度的評估指標，做句子相似度的比對，確認學生的作答是否有回答出重點概念。

(2) 評估指標

a. Sentence-BERT

特色是將句子轉化為具有「語義」的 embedding 向量，再利用 Cosine Similarity 將兩個句子的向量做相似度的計算。優點是 Sentence-BERT 可快速地將句子轉化成具有「語意理解」意義的向量。

b. BLEU

全名為 Bilingual Evaluation Understudy (雙語評估互補分數)，是一種對生成語句的評估指標。原理是使用語句中連續的 N 個單詞組成的片段 (N-gram) 做為計算單位，去計算生成語句的 N-gram 在人工標準語句的出現機率。優點是速度快易理解，缺點是不會考慮到語意的理解。

c. ROUGE

全名為 Recall-Oriented Understudy for Gisting Evaluation (摘要評估分數指標)。原理是透過統計兩句子重疊的基本單元，來評估兩句子的相似程度。ROUGE 的作者在論文中提出了 4 種 ROUGE 方法，我們採用了其中的 ROUGE-N 和 ROUGE-L 兩種指標。ROUGE-N 是在 N-gram 上計算召回率；而 ROUGE-L 則考慮了兩句子之間的最長公共子序列。

在機器翻譯、自動摘要、自然語言生成 (NLG) 任務中，前述的 BLEU 和 ROUGE 都是常用的無監督評估指標，共通點是兩者都是統計兩句子重疊單元的個數，並且沒辦法考慮到語意理解，而他們的差異在於 BLEU 是根據精確率 (Precision) 來衡量，ROUGE 則是根據召回率 (Recall) 來衡量。

(3) 方法：

將「學生的回答句」與「問題生成的答案句」使用上述的 Sentence-BERT、BLEU、ROUGE-N 和 ROUGE-L 等 4 個評估指標，進行句子相似度的比對，計算出加權平均分數，以衡量學生的答題精確度。

2. 問題評分


(1) 概念

在一篇中來自《科學教學研究雜誌》(Journal of Research in Science Teaching) 的心理學領域論文[6]指出，提問的品質可以藉由三個標準來評斷，分別是 orientation (方向、屬性)、relation (與文本的關係) 和 complexity (複雜程度)。而每個標準又可分為低、中、高三個等級。

我們期待能參考此論文所提出的三個標準，去對於 T5 所生成的問題，進行品質的篩選，分類題目的難度，避免出現同一份考卷中所有問題都過於簡單的窘境。

(2) 嘗試方法

訓練以 BERT 為基本架構的模型，原理是讓 BERT 吃進一個句子 (若輸入為文章，則視為是一個包括標點符號的超長句子)，將 [CLS] 這一項的 Embedding 輸出再接上分類器來訓練。訓練上的做法就是 Fine-tune 微調 BERT 並訓練分類器 BERTforSequenceClassification。



圖八、Fine-tune 微調 BERT 架構分類器示意圖

(3) 訓練細節

初步使用的訓練資料集，來自本實驗室「python 程式設計課程」蒐集的學生中文提問資料集，並且資料集已在前述 orientation、relation 和 complexity 等三個向度，做好評分標記，我們將此三個向度的分數取平均後，作為訓練模型的 label。

因為原始資料為中文資料，我們把句子資料逐一翻譯成英文後，再餵進 BERTforSequenceClassification 做 Fine-tune。

訓練相關參數方面，訓練優化器(Optimizer)使用 AdamW，learning_rate 為 2e-5 (預設 5e-5)，adam_epsilon 使用預設的 1e-8。而論文作者建議 BERT 的下游任務

Fine-tune 嘗試 2~4 個 epoch 即可，我們設定為 4 個 epoch。

四、專題研究成果及探討

(一)、「針對教材重點出題」任務：

1. PKE 關鍵字萃取成果

(1) 萃取關鍵字表現數據結果

我們發現使用 PKE (Python-Base Keyphrase Extraction) 萃取的關鍵字品質相較下表表現最好，平均約可在衡量模型好壞的 F1-score 指標中達到 80% 的水準！

Natural language processing tasks, such as question answering, machine translation, reading comprehension, and summarization, are typically approached with supervised learning on **task specific datasets**. We demonstrate that **language models** begin to learn these **tasks** **without** any explicit supervision when trained on a new dataset of millions of webpages called **WebText**.

Precision = $8/9 = 89\%$, Recall = $8/11 = 73\%$, F1-score = 80%

圖九、在展示用測試文本的關鍵字萃取表現示意圖

(2) 總結

PKE 優點包括能對關鍵字的重要性評分，且有許多不同的 Unsupervised models 和 Supervised models 可以套用測試，並可指定提取的關鍵字數量…等。因此我們決定選用 PKE 作為重點標記任務的模型。

2. T5 問題生成表現成果

(1) 問題生成表現客觀評估方法

在本專題「自動評分」任務中，學生回答句評分的各項指標 (BLEU、ROUGE…) 亦是自然語言生成 (NLG) 中常見的無監督評估方法。

為了客觀評估 T5 模型問題生成的表現，我們利用 SQuAD v1.0 問答資料集，它包含了上萬筆「短文」、「針對短文出的問題」以及「問題的解答」。我們擷取了一部份的「短文」作為測試資料，並利用 BLEU、ROUGE-1、ROUGE-L、Sentence-BERT 等指標來評估「T5 模型生成的問句」和「SQuAD v1.0 資料集內人工出題問句」的相似度分數。


計算方法是對於每個「SQuAD v1.0 資料集的人工出題問句」，在所有 T5 生成問句中搜尋與之比對分數最高的「T5 生成問句」，當作計算的相似度分數，以避免完全不同的問句，被納入比對而失準。

A	B	C	D	E	F	G	H	I	J	K
context	SQuAD Question	score_bleu	generated question_bleu	score_sentence-BERT	generated question_sentence-BERT	score_rouge-1	generated question_rouge-1	score_rouge-l	generated question_rouge-l	
296	Beyoncé's When did Beyoncé release her first solo album?	1	When did Beyoncé release her first solo album?	1.00000028	When did Beyoncé release her first solo album?	1	When did Beyoncé release her first solo album?	1	When did Beyoncé release her first solo album?	
271	Beyoncé Who is Beyoncé's biggest musical influence?	1	Who is Beyoncé's biggest musical influence?	0.99999762	Who is Beyoncé's biggest musical influence?	1	Who is Beyoncé's biggest musical influence?	1	Who is Beyoncé's biggest musical influence?	
338	Beyoncé How many octaves does Beyoncé have?	0.83333333	How many octaves does Beyoncé have?	0.97170035	How many octaves does Beyoncé have?	0.83333333	How many octaves does Beyoncé have?	0.83333333	How many octaves does Beyoncé have?	
	How many copies did 4 sell in the first week?	0.8	How many copies did 4 sell in the first week?	0.96172742	How many copies did 4 sell in the first week?	0.8	How many copies did 4 sell in the first week?	0.8	How many copies did 4 sell in the first week?	
	How many Grammy Awards has Beyoncé won?	0.71428571	How many Grammy Awards has Beyoncé won?	0.94480828	How many Grammy Awards has Beyoncé won?	0.71428571	How many Grammy Awards has Beyoncé won?	0.71428571	How many Grammy Awards has Beyoncé won?	
	What did she wear on the cover of L'Officiel?	0.66666667	What did she wear on the cover of L'Officiel?	0.93439418	What did she wear on the cover of L'Officiel?	0.66666667	What did she wear on the cover of L'Officiel?	0.66666667	What did she wear on the cover of L'Officiel?	
	How many Grammy Awards has Beyoncé won?	0.71428571	How many Grammy Awards has Beyoncé won?	0.92657389	How many Grammy Awards has Beyoncé won?	0.71428571	How many Grammy Awards has Beyoncé won?	0.71428571	How many Grammy Awards has Beyoncé won?	
	When was the Mrs. Carter Show Limited Edition released?	0.62279578	When was the Mrs. Carter Show Limited Edition released?	0.91699391	When was the Mrs. Carter Show Limited Edition released?	0.77777778	When was the Mrs. Carter Show Limited Edition released?	0.77777778	When was the Mrs. Carter Show Limited Edition released?	
	How many copies did B'Day sell?	0.31140324	How many copies did B'Day sell?	0.91366863	How many copies did B'Day sell?	1	How many copies did B'Day sell?	1	How many copies did B'Day sell?	
51	At the 52nd Annual Grammy Awards, how many nominations did Beyoncé receive?	0.58106402	How many Grammy nominations did Beyoncé receive?	0.91169256	How many Grammy nominations did Beyoncé receive?	0.63636363	How many Grammy nominations did Beyoncé receive?	0.54545454	How many Grammy nominations did Beyoncé receive?	
220	Beyoncé How many Grammy Awards has Beyoncé won?	0.42857142	How many Grammy Awards has Beyoncé won?	0.89041006	How many Grammy Awards has Beyoncé won?	0.42857142	How many Grammy Awards has Beyoncé won?	0.42857142	How many Grammy Awards has Beyoncé won?	
713	The female Who motivated Beyoncé to explore other musical genres?	0.4	Who inspired Beyoncé to explore other musical genres?	0.87628804	Who inspired Beyoncé to explore other musical genres?	0.4	Who inspired Beyoncé to explore other musical genres?	0.4	Who inspired Beyoncé to explore other musical genres?	
36	At age eight How old was Beyoncé when she met LaTavia Roberson?	0.30326533	When did Beyoncé meet LaTavia Roberson?	0.87283529	When did Beyoncé meet LaTavia Roberson?	0.5	When did Beyoncé meet LaTavia Roberson?	0.5	When did Beyoncé meet LaTavia Roberson?	
559	In November What was the name of the final album Destiny's Child released?	0.51546699	What was the last album Destiny's Child released?	0.87217651	What was the last album Destiny's Child released?	0.75	What was the last album Destiny's Child released?	0.75	What was the last album Destiny's Child released?	
81	Beyoncé What is the name of Beyoncé's younger sister?	0.6191985	Who is the younger sister of Beyoncé?	0.86876907	Who is the younger sister of Beyoncé?	0.83333333	What is the name of Beyoncé's younger sister?	0.83333333	What is the name of Beyoncé's younger sister?	
565	In November What is the name of the final album Destiny's Child released?	0.37908162	What was the last album Destiny's Child released?	0.86491251	What was the last album Destiny's Child released?	0.625	What was the last album Destiny's Child released?	0.625	What was the last album Destiny's Child released?	
249	Beyoncé I What year did Beyoncé introduce her first fragrance?	0.4953588	When did she launch her first fragrance?	0.86178094	When did Beyoncé launch her second fragrance?	0.57142857	When did she launch her first fragrance?	0.57142857	When did she launch her first fragrance?	
297	Beyoncé's What is the lead single from Beyoncé's first solo album?	0.55555556	What is the first single from Beyoncé's first solo album?	0.85913455	What was Beyoncé's first solo album?	0.66666667	What was Beyoncé's first solo album?	0.66666667	What was Beyoncé's first solo album?	
380	Following What was the name of Beyoncé's first solo album?	0.40435773	What was her first solo album?	0.85812004	What was Beyoncé's first album?	0.8	What was Beyoncé's first album?	0.8	What was Beyoncé's first album?	
219	Beyoncé How many Grammys has Beyoncé won?	0.57142857	How many Grammy Awards has Beyoncé won?	0.85369777	How many Grammy Awards has Beyoncé won?	0.57142857	How many Grammy Awards has Beyoncé won?	0.57142857	How many Grammy Awards has Beyoncé won?	
225	Beyoncé I What Beyoncé song was song?									
35	At age eight At what age did Beyoncé meet LaTavia Roberson?									
392	Forbes me What is Beyoncé's net worth?									

圖十、問題生成表現評估-問句相似度在各指標的分數結果

(2) 問題生成表現評估數據結果

以下呈現 SQuAD v1.0 資料集人工出題問句，與 T5 問題生成對應問句的句子相似度的數據統計結果。



圖十一、問句相似度在各指標的評估分數盒狀分布圖

SQuAD人工出題與T5問題生成句子相似度評估分數-數據統計				
	Sentence-BERT	BLEU	ROUGE-1	ROUGE-L
平均	0.883	0.718	0.861	0.859
標準差	0.052	0.113	0.067	0.072

表二、問句相似度在各指標的評估分數數據統計表

(3) 總結

在圖十一的 4 個指標分數的盒狀分布圖中，可以看到有 3 個指標基本上分數都在 0.8 以上，而分數較低的 BLEU，基本上也有在 0.6 以上。計算圖表二 4 個指標的總平均，可以發現整體總平均達 83%。由這些數據，我們認為 T5 生成問句已接近人工出題的水準！

(二)、「自動評分」任務：

1. 學生回答評分

學生回答評分部分的做法及概念皆和前述「T5 問題生成表現評估方法」類似，且使用的評估指標也相同，因此我們尚未進行這部份的學生作答實際評分實驗。但我們預期成果應能與「T5 問題生成表現評估方法」的結果相同，亦即能快速的對「學生回答句」與「問題生成參考答案句」做相似度的評分，並計算其平均作為最後的相似度成績，做為考試評分的參考。

2. 問題評分

(1) 訓練結果

下表呈現 BERTforSequenceClassification 對翻譯後的學生中文提問資料集的 Fine-tune 過程數據。

Epoch	1	2	3	4
Loss	0.96	0.83	0.73	0.68
Validation accuracy	0.61	0.67	0.71	0.69

表三、BERTforSequenceClassification 的 Fine-tune 過程數據

(2) 問題分析

由以上數據結果可見，最終 Validation accuracy 分數 0.69 的表現可能不是很理想，而基本上 BERT model 應無太大問題，換言之，問題較可能出在資料集上。

我們分析主要的原因除了資料集規模較小以外，還包括資料的 label 分數太過集中，主要集中在低分(1分)及中等分(2分)，約占了 8 成以上，高分(3分)的資料很少，資料分布黏稠度太高。

因此，我們認為可以嘗試的解法，就是重新對資料集做人工評分，或是對原始資料(3項分數)取最大值當分數，不使用平均的分數，降低資料黏稠度，分散資料、加大標準差！

(3) 總結

在問題評分這個部分我們認為尚有許多改進空間，除了資料集分析優化以外，還能再進一步研究、使用其他效能更好的 SOTA model 來做 Fine-tune 訓練！

五、未來展望

我們期許本專題在未來能有更成熟的發展，而在未來展望部分我們分為三個面向做討論。

1. **結合教學平台：**我們認為本專題可以結合教學平台，自動在學生教材上做重點筆記，提升學生閱讀的重點理解！另外，可以再配合網路爬蟲技術，抓取與課程重點相關的延伸資料，顯示在平台上，可以幫助學生不只侷限於課內教材，還能做課外的延伸學習！最終希望延伸到多國語言，讓各國師生都能受惠。
2. **結合文章摘要技術：**我們希望本專題能結合其他文章摘要技術，並進階延伸到對教材或網路文章快速生成文章摘要的功能。期許在這個資訊爆炸的時代，能幫助大眾快速吸收資訊，提高生活便利性。
3. **結合網路搜尋及爬蟲技術：**在平常閱讀文章或論文時，常會遇到對某些名詞不熟悉的問題，往往需要花費時間再做進一步的搜尋，閱讀相關文章來理解此名詞的相關概念。我們期待本專題未來的發展，能有機會透過結合爬蟲爬取大量相關資料，再利用萃取關鍵字及摘要模型，對於想了解的觀念或名詞，達到快速的重點節錄功能，幫助使用者迅速得到該觀念最核心的資訊。

六、參考文獻

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. [Attention is all you need](#). In *Advances in Neural Information Processing Systems*, pages 6000–6010.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. [Bert: Pre-training of deep bidirectional transformers for language understanding](#). *arXiv preprint arXiv:1810.04805*, 2018.
- [3] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. 2019. [Language models are unsupervised multitask learners](#). *OpenAI Blog*, 1(8):9.
- [4] Florian Boudin. 2016. [pke: an open source python-based keyphrase extraction toolkit](#). In *Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: System Demonstrations*, pages 69–73.
- [5] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. 2020. [Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer](#). *Journal of Machine Learning Research* 21, 140 (2020), 1–67.
- [6] Dori, Yehudit J., and Orit Herscovitz. 1999. Question-posing capability as an alternative evaluation method: Analysis of an environmental case study. *Journal of Research in Science Teaching: The Official Journal of the National Association for Research in Science Teaching* 36.4: 411-430.